

Técnicas de redução de dimensionalidade de dados para remoção de ruídos em imagens

Breno Ortiz Nalin¹, Cássio Machiaveli Oishi¹

¹Curso de Bacharelado em Ciência da Computação
Universidade Estadual Paulista "Júlio de Mesquita Filho" (UNESP)
19060200 – Presidente Prudente – SP – Brasil

breno.nalin@unesp.br, cassio.oishi@unesp.br

Abstract. *This paper investigates the performance of linear Principal Component Analysis (PCA) and non-linear Kernel PCA (KPCA) in dimensionality reduction and image denoising. The complexity of noisy, non-linear data poses challenges to efficient computational modeling. Using Optuna for hyperparameter optimization and spectral variance analysis, both methods were evaluated across various synthetic noise distributions applied to facial images. Results show that KPCA outperforms traditional PCA in reconstruction quality (highest PSNR) across all scenarios, demonstrating greater mathematical resilience to noise overfitting. However, standard PCA maintains an advantage in computational efficiency by requiring a lower-dimensional subspace.*

Resumo. *Este trabalho investiga o desempenho da Análise de Componentes Principais (PCA) linear e do Kernel PCA (KPCA) não-linear na redução de dimensionalidade e remoção de ruído em imagens. A complexidade de dados ruidosos e não-lineares impõe desafios à modelagem computacional eficiente. Utilizando otimização de hiperparâmetros com Optuna e análise espectral de variância, os métodos foram avaliados sob diversas distribuições de ruído sintético aplicadas a imagens faciais. Os resultados comprovam que o KPCA supera o PCA em qualidade de reconstrução (PSNR) em todos os cenários, apresentando maior resiliência matemática ao overfitting do ruído. Contudo, o PCA padrão mantém vantagem na eficiência computacional por exigir menor dimensionalidade.*

1. Introdução

A crescente disponibilidade de grandes volumes de dados e o avanço do poder computacional consolidaram as abordagens orientadas a dados como um paradigma central na modelagem de fenômenos complexos, notadamente em sistemas dinâmicos [Brunton and Kutz 2022]. No entanto, essa revolução enfrenta um obstáculo fundamental: o custo computacional proibitivo associado a simulações de alta fidelidade e a manipulação de dados em espaços de alta dimensionalidade. Para contornar essa limitação, as modelagens de ordem reduzida e os modelos substitutos surgem como ferramentas essenciais, buscando criar representações simplificadas e eficientes dos sistemas sem sacrificar suas características dinâmicas essenciais [Hou and Behdinan 2022].

Contudo, a eficácia na construção de um modelo de ordem reduzida não depende apenas da gestão da complexidade computacional. Ela é igualmente desafiada

por duas propriedades intrínsecas aos dados: a **não-linearidade** dos padrões subjacentes e a **contaminação por ruído**. Fenômenos como os observados na mecânica de fluidos exibem comportamentos notavelmente não-lineares que métodos simples não conseguem capturar [Mendez 2022]. Simultaneamente, o ruído — flutuações aleatórias inerentes à aquisição e transmissão de dados — pode degradar severamente o sinal original, comprometendo a extração de características e a confiabilidade de qualquer modelo subsequente, um risco crítico em aplicações de alto impacto como diagnósticos médicos.

Historicamente, a Análise de Componentes Principais (PCA), um método linear baseado na Decomposição por Valores Singulares (SVD), tem sido a abordagem padrão para a redução de dimensionalidade [Plaut 2018]. Apesar de sua robustez e interpretabilidade, sua premissa de linearidade limita sua aplicação em sistemas mais complexos. Para superar essa barreira, técnicas não-lineares foram desenvolvidas, com destaque para a aplicação do *kernel trick*. Ao mapear os dados para um espaço de características de maior dimensão onde as relações se tornam lineares, o *kernel trick* permite que algoritmos como o PCA sejam estendidos para capturar estruturas não-lineares, dando origem ao *Kernel PCA* [Honeine and Richard 2011].

Neste contexto, este trabalho se propõe a investigar e comparar o desempenho de métodos de redução de dimensionalidade lineares (PCA) e não-lineares (*Kernel PCA*) aplicados ao processamento de imagens, com foco específico na remoção de ruídos (*denoising*). Por meio da aplicação dessas técnicas em conjuntos de dados representativos, busca-se avaliar não apenas a eficiência computacional de cada abordagem, mas também sua capacidade de reconstruir fielmente a estrutura latente do sinal original, oferecendo uma análise crítica sobre suas respectivas vantagens e limitações em aplicações práticas.

2. Objetivos

2.1. Objetivo Geral

O objetivo geral deste trabalho é investigar e aplicar métodos de redução de dimensionalidade, com ênfase nas técnicas linear (PCA) e não-linear (*Kernel PCA*), para o tratamento de imagens digitais, visando especificamente a remoção de ruídos (*denoising*). Busca-se obter representações de baixa ordem da imagem que sejam computacionalmente eficientes e que preservem as características essenciais do sinal original, isolando o ruído. Adicionalmente, o desenvolvimento deste Trabalho de Conclusão de Curso visa proporcionar ao discente uma introdução ao método científico e a um escopo de pesquisa avançado, contribuindo para sua formação acadêmica e aprimorando sua capacidade de resolver problemas complexos na área de processamento de sinais, visão computacional e modelagem computacional.

2.2. Objetivos Específicos

Para alcançar o objetivo geral, os seguintes objetivos específicos serão perseguidos:

- Realizar uma revisão teórica aprofundada dos fundamentos matemáticos da Análise de Componentes Principais (PCA) e sua aplicação em contextos de processamento de imagens como base para a redução de dimensionalidade.
- Investigar a formulação do *Kernel PCA*, compreendendo a aplicação do *kernel trick* para estender a PCA a um espaço de características não-linear, permitindo a captura de padrões complexos e a separação de ruídos com distribuição não-linear.

- Aplicar os métodos estudados em conjuntos de imagens digitais sinteticamente ruidosas, utilizando-se da redução e posterior reconstrução da dimensionalidade como método de *denoising*.
- Analisar e comparar o desempenho dos métodos de *denoising* baseados nas abordagens linear e não-linear por meio de métricas objetivas (como PSNR), avaliando a qualidade da imagem reconstruída e a eficiência computacional de cada método na tarefa de remoção de ruído.

3. Metodologia

O desenvolvimento do projeto seguiu uma abordagem metodológica em quatro etapas sequenciais, começando com a fundamentação teórica e progredindo para a aplicação prática e otimização avançada dos métodos de redução de dimensionalidade na tarefa de *denoising* de imagens. Todos os códigos usados podem ser vistos no repositório do GitHub¹.

3.1. Etapa I: Fundamentação e Análise Exploratória com PCA

A primeira etapa teve como foco a compreensão fundamental do funcionamento da Análise de Componentes Principais (PCA) em um contexto de dados não-imagético.

- **Conjunto de Dados:** Foi utilizado o *dataset* de vinhos (Wine Dataset), escolhido por sua natureza tabular e dimensionalidade moderada, facilitando a visualização e interpretação dos resultados.
- **Aplicação do PCA:** O PCA é um método linear que transforma o conjunto de dados original $X \in R^{n \times d}$ (onde n é o número de amostras e d é a dimensionalidade original) em um novo conjunto de componentes Z não correlacionados. Isso é alcançado através da decomposição da matriz de covariância $C = \frac{1}{n-1}(X - \bar{X})^T(X - \bar{X})$ [Brunton and Kutz 2022], onde $\bar{X}$ representa a média calculada ao longo das colunas da matriz de dados (isto é, a média individual de cada característica ou variável). A solução do problema de autovalor para esta matriz, dado por:

$$Cv_i = \lambda_i v_i$$

fornece os autovetores v_i (as Componentes Principais - CPs) e os autovalores λ_i (a variância explicada por cada componente).

O objetivo foi **encontrar as três primeiras Componentes Principais (CPs)**, formando a matriz de projeção $W = [v_1, v_2, v_3]$ com os autovetores correspondentes aos três maiores autovalores.

3.2. Etapa II: Aplicação Controlada de Denoising (PCA e Kernel PCA)

Com a compreensão básica estabelecida, a segunda etapa migrou para o domínio da aplicação em imagens e a introdução da abordagem não-linear (*Kernel PCA*).

- **Conjunto de Dados de Imagens:** Foi empregado um *dataset* contendo imagens de dígitos (USPS, do OpenMI²), ideal para o teste controlado devido à sua estrutura de pixels.

¹<https://github.com/ppbreno/Codigos-IC>

²<https://www.openml.org/search?type=data&status=active&id=41082&sort=runs>

- **Injeção de Ruído:** Foi aplicado ruído sintético (controlado) nas imagens originais, simulando o cenário de degradação de dados.
- **Denoising e Reconstrução:** Os métodos PCA e *Kernel PCA* foram aplicados. Para introduzir a não-linearidade, o *Kernel PCA* (KPCA) primeiro mapeia os dados x para um espaço de características F de alta dimensão através de uma função Φ , tal que $x \mapsto \Phi(x)$. A PCA é então realizada em F . O "truque do *kernel*" (*kernel trick*) evita o cálculo explícito de Φ , definindo uma matriz de *kernel* K onde $K_{ij} = \Phi(x_i)^T \Phi(x_j) = k(x_i, x_j)$. Após a centralização de K para $\tilde{K}$, o problema de autovalor é resolvido em $\tilde{K}\alpha = \lambda\alpha$, onde os vetores α representam as componentes no espaço de características [Bui et al. 2019]. A remoção de ruído (*denoising*) é obtida usando este processo. Para o PCA, os dados ruidosos X_{ruidoso} são projetados em um subespaço de r dimensões $Z_r = (X_{\text{ruidoso}} - \bar{X})W_r$ (onde W_r contém as r primeiras CPs) e então reconstruídos: $X_{\text{denoised}} = Z_r W_r^T + \bar{X}$. Para o KPCA, a reconstrução (o "problema da pré-imagem") é mais complexa, pois requer a inversão do mapeamento Φ , que é frequentemente aproximada.
- **Avaliação Métrica Inicial:** A performance do *denoising* foi avaliada utilizando o **Erro Quadrático Médio (MSE)** e a **Peak Signal-to-Noise Ratio (PSNR)**. Sendo I a imagem original e D a imagem reconstruída (*denoised*), ambas de dimensões $m \times n$, o MSE é dado por:

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} [I(i, j) - D(i, j)]^2$$

A PSNR, medida em decibéis (dB) e que quantifica a qualidade da reconstrução, é definida como:

$$PSNR = 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right)$$

onde MAX_I é o valor máximo possível de um pixel (e.g., 255 para imagens de 8 bits). Valores de MSE menores e PSNR maiores indicam melhor reconstrução.

3.3. Etapa III: Otimização Automatizada de Hiperparâmetros e Comparação Exaustiva

A terceira etapa consistiu em uma análise detalhada do espaço de hiperparâmetros do KPCA para diferentes tipos de ruído. Para lidar com a complexidade do problema, a variação manual inicial foi substituída por uma abordagem de otimização automatizada.

- **Conjunto de Dados de Faces:** Foi utilizado o *dataset fetch_olivetti_faces*, que representa um desafio de dimensionalidade e complexidade maior que o de dígitos.
- **Espaço de Hiperparâmetros (H):** A eficácia do KPCA é ditada pela escolha da função de *kernel* $k(x_i, x_j)$ e seus respectivos parâmetros. O espaço de busca estruturado para a otimização englobou as seguintes funções e variáveis:
 - **Kernel Linear:** $k(x, y) = x^T y$.
 - **Kernel Polinomial (*poly*):** $k(x, y) = (\gamma x^T y + c_0)^d$. Os hiperparâmetros associados são *gama* (γ), *coeficiente* (c_0) e *grau* (d).

- **Kernel RBF (Base Radial):** $k(x, y) = \exp(-\gamma\|x - y\|^2)$, controlado por *gamma* (γ).
- **Kernel Sigmoidal (*sigmoid*):** $k(x, y) = \tanh(\gamma x^T y + c_0)$, controlado por *gamma* (γ) e *coeficiente* (c_0).
- **Kernel Cosseno (*cosine*):** $k(x, y) = \frac{x^T y}{\|x\|\|y\|}$.
- **Alfa (α):** Parâmetro de regularização de Tikhonov empregado no *solver* da transformação inversa (problema da pré-imagem) para estabilizar a solução.
- **Otimização com Optuna:** A biblioteca **Optuna** foi utilizada como ferramenta principal para explorar o espaço de parâmetros H de maneira eficiente. O problema foi modelado formalmente onde, para um vetor de hiperparâmetros $h \in H$, a função objetivo $f(I_{\text{original}}, X_{\text{ruidoso}}, h)$ a ser maximizada é o PSNR da imagem reconstruída D , que é uma função dos dados ruidosos X_{ruidoso} e de h :

$$f(I_{\text{original}}, X_{\text{ruidoso}}, h) = \text{PSNR}(I_{\text{original}}, D(X_{\text{ruidoso}}, h))$$

Assim, o algoritmo busca o conjunto ótimo h^* que maximiza a qualidade da reconstrução para cada tipo de ruído aplicado:

$$h^* = \arg \max_{h \in H} f(I_{\text{original}}, X_{\text{ruidoso}}, h)$$

- **Registro e Compilação de Resultados:** Para cada iteração avaliada pelo Optuna, as métricas de MSE e PSNR foram calculadas. Ao final do processo, os resultados foram exportados e compilados em um novo *dataset*, gerando tabelas comparativas com os melhores hiperparâmetros encontrados e servindo de base para as conclusões finais sobre a eficácia de cada abordagem.

3.4. Etapa IV: Análise Espectral e Avaliação de Variância (Sinal vs. Ruído)

A quinta e última etapa dedicou-se à avaliação espectral profunda dos métodos, com o objetivo de quantificar e visualizar a capacidade do PCA e do KPCA em discriminar padrões estruturados (sinal latente) da aleatoriedade pura (ruído branco).

- **Isolamento do Ruído:** Para garantir uma análise comparativa rigorosa do comportamento dos algoritmos, o ruído gaussiano puro foi isolado matematicamente a partir da diferença entre a matriz de imagens degradadas e a matriz de imagens originais:

$$X_{\text{ruído}} = X_{\text{ruidoso}} - X$$

- **Compatibilização Matemática (*Eigenvalues vs. Singular Values*):** Uma vez que o PCA linear padrão é frequentemente resolvido via Decomposição em Valores Singulares (SVD), gerando valores singulares (s_i), foi necessário converter essas medidas para a escala de variância estatística (autovalores, λ_i). Isso garantiu uma comparação justa com o *Kernel PCA*, que resolve o problema de autovalor diretamente. A equivalência foi estabelecida pela equação:

$$\lambda_i = \frac{s_i^2}{n - 1}$$

onde n representa o número total de amostras. Paralelamente, os autovalores extraídos da matriz de *Kernel* no KPCA foram normalizados pelo fator n para alinhar as grandezas entre os espaços linear e não-linear.

- **Análise Gráfica de Energia Acumulada:** O comportamento da extração de características foi avaliado por meio da plotagem da proporção da variância explicada. Foram construídos gráficos de energia acumulada computando a soma da variância retida até o k -ésimo componente em relação à variância total do sistema:

$$E_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^d \lambda_j}$$

onde d é o limite máximo de componentes analisados.

- **Determinação Visual do Limite de *Overfitting*:** A sobreposição das curvas de variância extraída do sinal original (imagens de faces) com as curvas extraídas do ruído puro permitiu uma análise de intersecção. O uso de escalas logarítmicas e lineares nos eixos facilitou a identificação visual do ponto de saturação — o componente exato a partir do qual o algoritmo cessa a reconstrução de características estruturais e passa a incorporar exclusivamente o ruído aos dados projetados. Esta etapa comprovou graficamente a resiliência comparativa da abordagem polinomial otimizada frente ao método linear na presença de degradação.

4. Resultados e Discussão

Esta seção apresenta os resultados obtidos ao longo das etapas do projeto, iniciando com a avaliação exploratória de dados tabulares e avançando para a otimização na remoção de ruídos em imagens. Os resultados brutos da análise exaustiva de hiperparâmetros foram compilados em arquivos CSV, que podem ser acessados no repositório do GitHub³.

4.1. Análise Exploratória Inicial (Redução de Dimensionalidade)

Como resultado da primeira etapa do estudo, a projeção do conjunto de dados tabular no espaço de dimensionalidade reduzida comprovou a capacidade de extração de características do método linear. A Figura 1 apresenta os gráficos de dispersão dos dados originais projetados, $Z = (X - \bar{X})W$, nas três primeiras Componentes Principais (CPs), bem como a visualização bidimensional dos dados em cada par de componentes. Essa análise visual permitiu a interpretação da variância retida por cada CP e a verificação empírica da separabilidade das classes no espaço de baixa dimensão, validando o comportamento do algoritmo antes de sua aplicação em imagens de alta complexidade.

4.2. Análise Comparativa de Desempenho em *Denoising* (PSNR)

Avançando para a etapa em imagens faciais, a análise comparativa entre a Análise de Componentes Principais (PCA) e o *Kernel PCA* (KPCA), ambos otimizados para a tarefa de remoção de ruído (*denoising*), revelou aspectos importantes sobre a aplicabilidade de cada técnica frente a diferentes tipos de degradação. Os resultados da otimização dos hiperparâmetros, visando à maximização do PSNR (*Peak Signal-to-Noise Ratio*), estão sumarizados nas Tabelas 1 (KPCA) e 2 (PCA). A Figura 2 permite a visualização das reconstruções com os melhores hiperparâmetros do KPCA.

A Tabela 1 apresenta os resultados ótimos de PSNR obtidos pela técnica de KPCA otimizada com a ferramenta Optuna, detalhando os hiperparâmetros correspondentes. A Tabela 2 exhibe os resultados ótimos alcançados pelo PCA, para fins de comparação direta.

³<https://github.com/ppbreno/Codigos-IC/tree/main/IC-Results>




Figura 1. Projeção do *Wine Dataset* no espaço de características reduzido. Acima, a visualização tridimensional nas três primeiras Componentes Principais (CPs). Abaixo, as projeções bidimensionais isoladas, evidenciando a separabilidade linear das três classes do conjunto de dados.

Ruído	Kernel	PSNR (dB)	Componentes	Alfa	Gama	Grau	Coef.
Gaussiano	RBF	25.01	148	0.0000212	0.000239	—	—
Localvar	Poly	25.00	125	7.7034	0.0000140	5	8
Sal	RBF	23.56	94	0.000897	0.001595	—	—
Pimenta	RBF	22.81	97	0.000160	0.000544	—	—
Sal e Pimenta	RBF	23.84	143	0.000291	0.000748	—	—
Poisson	Poly	28.83	200	0.2291	0.0000424	4	9
Speckle	Poly	27.51	200	1.2506	0.008517	2	7

Tabela 1. Resultados da otimização de hiperparâmetros para o Kernel PCA (KPCA), exibindo o PSNR máximo alcançado por tipo de ruído.

Ruído	PSNR (dB)	Componentes
Gaussiano	24.02	53
Localvar	24.01	55
Sal	23.07	39
Pimenta	22.42	35
Sal e Pimenta	23.29	39
Poisson	27.82	170
Speckle	26.52	123

Tabela 2. Resultados da otimização do número de componentes para o PCA, exibindo o PSNR máximo e a dimensionalidade retida por tipo de ruído.




Figura 2. Reconstruções usando os melhores hiperparâmetros do Kernel PCA

- **Superioridade do KPCA:** Em todas as classes de ruído avaliadas, o *Kernel PCA* demonstrou desempenho superior em termos de PSNR quando comparado ao PCA. A diferença mais acentuada foi observada para o ruído **Poisson** (28.83 dB no KPCA vs. 27.82 dB no PCA) e o ruído **Speckle** (27.51 dB no KPCA vs. 26.52 dB no PCA). O que corrobora a hipótese de que a projeção em um espaço de características não-linear (via *kernel trick*) possui maior eficácia na separação de componentes de ruído com estruturas complexas.
- **Desafio dos Ruídos Impulsivos:** Ruídos da categoria *salt and pepper* (Sal, Pimenta, e Sal e Pimenta) apresentaram os valores de PSNR mais baixos em ambas as técnicas. Tal comportamento é atribuído à natureza impulsiva desses ruídos, que introduz valores de pixel extremos (saturação), sendo notoriamente mais desafiadores para a mitigação por métodos baseados em decomposição espectral.

4.3. Dimensionalidade do Modelo e Custo Computacional

A otimização forneceu informações cruciais sobre o número ideal de componentes a serem retidas para a reconstrução da imagem:

- **Dimensionalidade do Subespaço de Características:** O PCA (Tabela 2) consistentemente reteve um número menor de componentes para atingir seu PSNR ótimo (ex: 53 para Gaussiano, 35 para Pimenta). Isso implica um modelo de ordem reduzida e, conseqüentemente, computacionalmente mais eficiente. Em contraste, o KPCA (Tabela 1) frequentemente demandou um número maior de componentes (ex: 148 para Gaussiano, 200 para Poisson e Speckle), indicando que a captura de variância relevante no espaço não-linear requer um subespaço de maior dimensionalidade.
- **Compromisso (*Trade-off*) Eficiência-Acurácia:** A disparidade no número de componentes sugere um claro compromisso: o KPCA oferece maior acurácia (PSNR mais alto) ao custo de uma maior complexidade computacional, enquanto o PCA oferece maior eficiência (menor dimensionalidade).

4.4. Análise da Otimização dos Kernels

Os resultados do KPCA na Tabela 1 revelam a adaptabilidade da técnica a diferentes distribuições de ruído através da seleção do kernel:

- **Eficácia do Kernel RBF:** O *kernel* de Função de Base Radial (RBF) demonstrou ser o mais eficaz para ruídos **Gaussiano**, **Sal**, **Pimenta** e **Sal e Pimenta**. O RBF é um *kernel* de aplicação universal que mapeia dados para um espaço de dimensão infinita, demonstrando alta eficácia contra ruídos aditivos e com distribuição mais homogênea.
- **Aplicação do Kernel Polinomial:** Para os ruídos **Poisson** e **Speckle**, o *kernel* Polinomial (*Poly*) obteve desempenho superior. Frequentemente, estes ruídos apresentam dependência da intensidade do sinal (como o ruído multiplicativo *Speckle*), e o *kernel* Polinomial, com seus parâmetros *Grau* e *Coeff.* devidamente otimizados, logrou modelar com maior precisão essa relação não-linear complexa.

4.5. Avaliação Espectral e Limite de *Overfitting*

Para aprofundar a compreensão dos resultados de dimensionalidade obtidos na otimização (Tabelas 1 e 2), procedeu-se a uma análise espectral da variância explicada pelos compo-

nentes do PCA e KPCA. O objetivo foi visualizar a capacidade matemática de cada modelo em separar o sinal latente (estrutura facial) do ruído branco (aleatoriedade espacial). A Figura 3 ilustra o decaimento dos autovalores (variância) para os dados originais e para o ruído isolado.




Figura 3. Comparativo espectral (PCA Linear vs. KPCA com kernel RBF) ilustrando a variância retida por componente para o sinal original e para o ruído isolado em escala logarítmica.

A partir da análise visual e estatística do espectro de energia, destacam-se as seguintes observações que corroboram o comportamento empírico dos modelos:

- **Natureza do Ruído vs. Sinal:** Como esperado teoricamente, a variância do ruído puro (linhas tracejadas) distribui-se de maneira quase uniforme ao longo de todos os componentes, evidenciando a ausência de uma estrutura latente. Em contrapartida, as imagens de faces (linhas contínuas) apresentam um decaimento exponencial acentuado, confirmando que a vasta maioria da informação estrutural da imagem está concentrada nos primeiros componentes principais.
- **O Ponto de Saturação no PCA Linear:** A análise do gráfico linear (azul) revela o exato momento em que ocorre o *overfitting* visual. Observa-se que, próximo ao componente 50, a curva de variância do sinal original intercepta e se iguala à curva de variância do ruído puro. Isso explica matematicamente o resultado empírico apresentado na Tabela 2, onde o número ótimo de componentes encontrado pelo Optuna para o ruído Gaussiano foi exatamente 53. A adição de componentes além deste limiar no PCA linear não contribui para a reconstrução da face, mas sim para a reintrodução do ruído na imagem filtrada.
- **Resiliência e Espaço de Características do KPCA:** Diferentemente do modelo linear, a projeção não-linear do KPCA (curvas vermelhas) mantém um distanciamento (*gap*) mais consistente entre a energia extraída da face e a energia do ruído, mesmo em componentes de ordem superior. Esta resiliência matemática à confusão com o ruído justifica o fenômeno observado na Tabela 1, onde o KPCA conseguiu utilizar subespaços de dimensionalidade consideravelmente maior (e.g., 148 a 200 componentes) para capturar sutilezas não-lineares da imagem, maximizando a separação entre o sinal e o ruído.

zando o PSNR sem o prejuízo imediato da reintrodução de características puramente estocásticas.

Dessa forma, a análise espectral não apenas valida os hiperparâmetros de dimensionalidade encontrados pelos métodos heurísticos de busca do Optuna, mas também ilustra graficamente a superioridade do KPCA em segregar distribuições de dados complexas na presença de degradação severa.

A Figura 4 complementa a análise espectral ao apresentar a proporção da variância acumulada (energia) em função do número de componentes. Esta visualização permite quantificar o percentual de informação total retida pelo modelo ao ser truncado em uma determinada dimensionalidade k .




Figura 4. Proporção da variância acumulada capturada em função do número de componentes para o PCA e KPCA (Sinal Original vs. Ruído Isolado).

A partir desta representação, extraem-se interpretações adicionais sobre a dinâmica de compressão e modelagem de ambas as técnicas:

- **Taxa de Compressão de Informação:** As curvas referentes às imagens originais de faces (linhas contínuas) apresentam um crescimento inicial abrupto. Isso evidencia que uma quantidade reduzida de componentes já é capaz de reter a maior parte da energia estrutural da imagem. Em contrapartida, as curvas correspondentes ao ruído (linhas tracejadas) exibem um crescimento contínuo e mais linear, comportamento característico de variáveis aleatórias decorrelacionadas, onde cada novo componente adiciona apenas uma fração marginal de variância.
- **Considerações Teóricas sobre a Não-Linearidade:** É imperativo ressaltar uma distinção matemática fundamental na interpretação comparativa destes gráficos. No domínio do PCA padrão, por tratar-se de uma transformação estritamente linear, o princípio da superposição é válido. No entanto, no *Kernel PCA*, devido à natureza não-linear do mapeamento espacial, a transformação da imagem ruidosa não equivale à soma das transformações do sinal e do ruído independentes. Ou seja, avaliar o ruído isoladamente no KPCA não representa de forma exata como o ruído interage com o sinal no espaço de características de alta dimensão.

- **Heurística de Resiliência:** Apesar da limitação teórica inerente ao princípio da superposição em espaços não-lineares, a avaliação isolada fornece uma forte heurística interpretativa. A curva de energia acumulada demonstra que o espaço de características induzido pelo KPCA (neste caso, com *kernel* RBF) é geometricamente inclinado a priorizar a modelagem de interações estruturais subjacentes ao invés da aleatoriedade. Isso justifica o motivo empírico pelo qual o método obteve os maiores valores de PSNR na otimização, conseguindo extrair o sinal de forma mais eficiente mesmo quando o ruído não pode ser linearmente dissociado da imagem original.

5. Conclusão

Este trabalho investigou de forma sistemática o desempenho da Análise de Componentes Principais (PCA) e do *Kernel* PCA (KPCA) na complexa tarefa de redução de dimensionalidade e remoção de ruídos em imagens. A integração de uma metodologia rigorosa, que avançou da fundamentação teórica até a otimização automatizada de hiperparâmetros com a biblioteca Optuna, permitiu uma avaliação objetiva e profunda das capacidades e limitações das abordagens lineares e não-lineares.

Os resultados empíricos evidenciaram a superioridade do KPCA na qualidade de reconstrução do sinal, alcançando consistentemente os maiores valores de PSNR em todas as distribuições de ruído sintético testadas. A aplicação do *kernel trick*, com destaque para os *kernels* RBF e Polinomial, provou-se altamente eficaz para modelar as complexas interações estruturais presentes nas imagens faciais degradadas. Em contrapartida, o PCA linear demonstrou sua principal vantagem na eficiência computacional, necessitando de um subespaço de dimensionalidade significativamente menor para atingir seu ponto ótimo de reconstrução. Esse cenário evidencia um claro compromisso (*trade-off*) em aplicações práticas: o KPCA oferece maior acurácia analítica, enquanto o PCA garante menor custo computacional.

A etapa de análise espectral consolidou os achados empíricos com um embasamento matemático robusto. A visualização do decaimento da variância e da energia acumulada permitiu identificar com precisão o limiar de *overfitting* do modelo linear — o ponto exato em que o PCA cessa a reconstrução facial e passa a modelar o ruído estocástico. Simultaneamente, comprovou-se a maior resiliência espacial do KPCA, que consegue preservar um distanciamento energético consistente entre a estrutura latente e o ruído branco, justificando sua capacidade de operar eficientemente em dimensões mais elevadas.

Apesar dos resultados promissores, as dificuldades observadas na mitigação de ruídos de natureza impulsiva (como Sal e Pimenta) revelam limitações inerentes aos métodos puramente baseados em decomposição espectral. Como trabalhos futuros, sugere-se a exploração de métodos avançados para a resolução algébrica do problema da pré-imagem no KPCA, bem como a comparação quantitativa destas técnicas clássicas com arquiteturas modernas de aprendizado profundo, como *Autoencoders* convolucionais.

Em suma, a pesquisa atinge seu objetivo ao fornecer um arcabouço analítico sólido que orienta a escolha de algoritmos de redução de dimensionalidade no processamento de sinais, contribuindo ativamente para a modelagem computacional eficiente de sistemas orientados a dados.

Referências

- Brunton, S. L. and Kutz, J. N. (2022). *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. Cambridge University Press, Cambridge, England, UK.
- Bui, A. T., Im, J.-K., Apley, D. W., and Runger, G. C. (2019). Projection-free kernel principal component analysis for denoising. *Neurocomputing*, 357:163–176.
- Honeine, P. and Richard, C. (2011). Preimage Problem in Kernel-Based Machine Learning. *IEEE Signal Process. Mag.*, 28(2):77–88.
- Hou, C. K. J. and Behdinan, K. (2022). Dimensionality Reduction in Surrogate Modeling: A Review of Combined Methods. *Data Sci. Eng.*, 7(4):402–427.
- Mendez, M. A. (2022). Linear and Nonlinear Dimensionality Reduction from Fluid Mechanics to Machine Learning. *arXiv*.
- Plaut, E. (2018). From Principal Subspaces to Principal Components with Linear Auto-encoders. *arXiv*.